Elementi di Probabilità e Statistica per l'ICT
Tesina Numero 1: Analisi di Rete con Wireshark

Andrea D'Amico
Ingegneria Informatica (L-8) — Università degli studi di Catania

Indice

1 Introduzione all'Analisi dei Pacchetti **1**

2 Tempi di Interarrivo e Statistiche Descrittive **1**
2.1 Frequenze Cumulative 2

3 Classificazione per Tipo di Protocollo **3**
3.1 Istogramma dei Protocolli 3
3.2 Distribuzione Percentuale 3

4 Conclusioni **3**

1 Introduzione all'Analisi dei Pacchetti

Sono stati catturati 200 pacchetti mediante il software Wireshark tramite l'interfaccia di rete `Ethernet`. I dati sono stati successivamente esportati in formato CSV per facilitare l'elaborazione tramite script Python. Questo elaborato descrive l'analisi statistica dei tempi di interarrivo e la distribuzione dei protocolli di rete.

Il dataset è composto da $N = 200$ campioni prelevati dalla traccia `capture.pcapng`.

2 Tempi di Interarrivo e Statistiche Descrittive

Siano $t_1, t_2, \ldots, t_{200}$ gli istanti temporali di arrivo dei pacchetti registrati. Definiamo tempo di interarrivo la variabile aleatoria:

$$X(t_i) = t_i - t_{i-1} \quad \text{per } i = 2, \ldots, 200. \tag{1}$$

Il valore atteso (o media) della variabile aleatoria X è definito tramite l'integrale:

$$E[X] = \mu_X = \int_{-\infty}^{+\infty} x f_X(x)\, dx \tag{2}$$

Inoltre, la varianza σ_X^2 può essere calcolata esplicitamente come la differenza tra il valore quadratico medio $m_X^2 = E[X^2]$ e la media teorica al quadrato:

$$\sigma_X^2 = m_X^2 - \mu_X^2 = \left(\int_{-\infty}^{+\infty} x^2 f_X(x)\, dx \right) - \mu_X^2 \tag{3}$$

Dato che la traccia acquisita è formata da dati discreti e finiti, per il calcolo delle deviazioni e delle statistiche campionarie sui 199 intertempi si è sfruttata la libreria standard di Python:

```
import statistics
inter_arrival_times = [times[i] - times[i-1] for i in range(1, len(times))]

mean_iat = statistics.mean(inter_arrival_times)
stdev_iat = statistics.stdev(inter_arrival_times)
```

I risultati ottenuti dall'elaborazione numerica sono riassunti nella seguente tabella:

Parametro Statistico	**Valore [secondi]**
Media Campionaria ($\bar{x}$)	0.067018
Mediana (Q_2)	0.009945
Deviazione Standard Campionaria (s)	0.155533

Tabella 1: Indici di posizione e variabilità dei tempi di interarrivo.

C'è una differenza sostanziale tra media e mediana. Questo succede spesso nel traffico di rete reale, per via dei pacchetti "burst" che arrivano vicinissimi tra di loro, seguiti da pause lunghe che alterano la distribuzione.

2.1 Frequenze Cumulative

Per un modello continuo la Funzione di Distribuzione Cumulativa (CDF) può essere riscritta come:

$$F_X(x) = P(X \leq x) = \int_{-\infty}^{x} f_X(t)\, dt$$

Attraverso il calcolo numerico in Python e l'uso di librerie grafiche, è stata tracciata la CDF empirica al fine di mostrare l'andamento della probabilità cumulativa dei dati:

```
sorted_iat = np.sort(inter_arrival_times)
y_values = np.arange(len(sorted_iat)) / float(len(sorted_iat) - 1)
plt.plot(sorted_iat, y_values, marker='.', linestyle='none')
```

Il grafico risultante è il seguente:

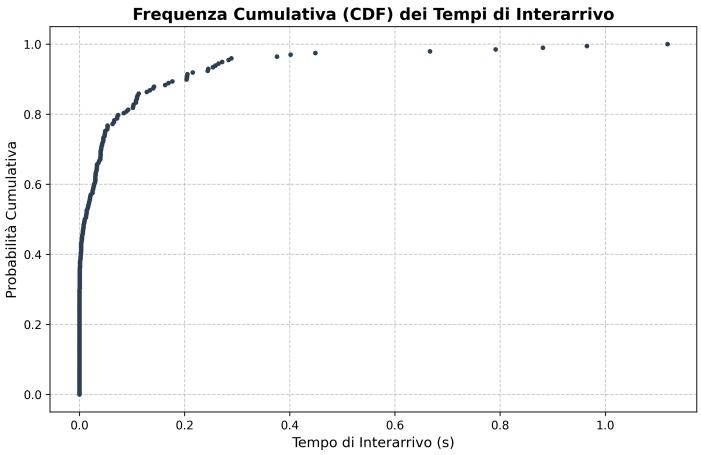

Figura 1: Grado di probabilità cumulativa per i tempi di interarrivo dei pacchetti catturati.

3 Classificazione per Tipo di Protocollo

L'analisi successiva è mirata ad identificare le tipologie di protocolli presenti nella sessione catturata. Ad esempio il DNS e l'ARP, protocolli fondamentali, risultano rilevati in quantità significative nel traffico ordinario.

La tabella seguente riporta il conteggio dei principali protocolli estratti dal file CSV:

Protocollo	Conteggio Pacchetti
TCP	60
UDP	28
TLSv1.2	28
DNS	24
ARP	22
Altri	38

3.1 Istogramma dei Protocolli

L'istogramma evidenzia in modo chiaro come il traffico complessivo sia fortemente dominato dal TCP, protocollo di livello trasporto impiegato tipicamente per garantire l'assenza di perdite.

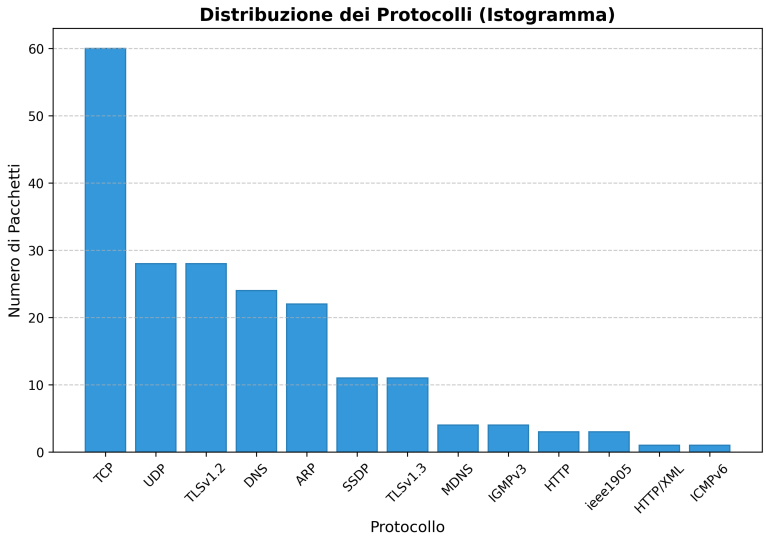

Figura 2: Distribuzione del numero di pacchetti per tipologia di protocollo.

3.2 Distribuzione Percentuale

La suddivisione percentuale è rappresentata tramite un grafico a torta. In fase di generazione grafica dello script, è stata applicata una logica condizionale al fine di aggregare i protocolli minoritari sotto la dicitura unica "Others", migliorandone dunque la leggibilità:

```
if len(sorted_protos) > 6:
    top_protos = list(sorted_protos.items())[:5]
    others_count = sum(count for label, count in list(sorted_protos.items())[5:])
```

4 Conclusioni

In conclusione, i dati raccolti indicano un flusso temporale per nulla omogeneo, presentando una variabilità elevata rispetto ai valori medi ($s = 0.155$ s a fronte di una media $\bar{x} = 0.067$ s). Queste evidenti fluttuazioni sono coerenti con una sessione di normale navigazione web. Infine, la netta predominanza del traffico TCP conferma pienamente questa destinazione d'uso.

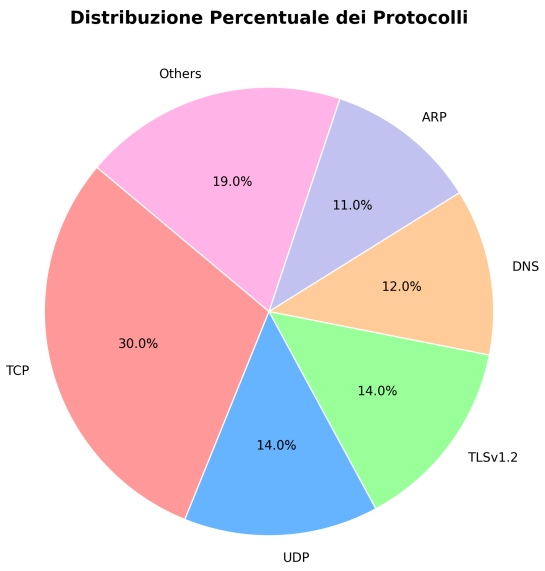

Figura 3: Ripartizione percentuale dei protocolli catturati.

Questo documento e il relativo codice sono ospitati all'interno di un repository pubblico su GitHub.
`https://github.com/andreadamico678/tesine-teoria-dei-segnali`